

UITEENZETTING

De specialisten in de LLM-suite

Wat elke lane toetst, hoe een antwoord wordt gescoord, en voorbeeldvragen die op de suite lijken zonder de gescoorde packs te herhalen.

De gewone batterij (GSM8K, TruthfulQA, BBH, MMLU, HumanEval) meet brede taal- en redeneervaardigheid. De specialistische suite is een tweede, optionele laag. Zij vraagt of een model een smal vak aankan wanneer het antwoord controleerbaar is: een letter, een getal dat uit een formule volgt, een JSON-commando dat een simulator kan narekenen, of een videofilter dat lokaal rendert. Geen van deze scores telt mee in de algemene Composite.

Elke lane leest een lokale CSV. Het model krijgt de vraag en vier opties, of bij FQ en Video een opdracht zonder antwoordsleutel. De kolommen answer en notes gaan niet de prompt in. Een liggend streepje op het dashboard betekent dat de lane voor dat model niet is gedraaid. Het is geen nul.

De voorbeelden hieronder zijn nieuw geschreven voor dit document. Zij gebruiken andere getallen, andere situaties en andere tickers dan de packs. Zij worden niet gescoord.

Hoe een beurt verloopt

Bij een meerkeuzelane luidt de opdracht: redeneer privé, en eindig met alleen de letter. De scorer zoekt de eerste losse letter A-D. Een lang betoog dat de juiste letter noemt, telt dus mee, maar een betoog zonder letter telt niet. Bij Finance en de andere CSV-lanes is de limiet 768 antwoordtokens. Dat is genoeg voor een korte afleiding en te krap voor een essay.

Vision slaat een text-only model over en schrijft unsupported. De MiMo-run van 24 september 2026 is text-only en draait Vision daarom niet. Finance is op 24 september toegevoegd. Het proces dat toen al liep, had de oude lijst geladen en stelt deze 24 vragen niet. Het volgende model wel.

De negen lanes

Lane	Aantal	Wat het model moet doen	Hoe de score ontstaat
Chemistry	6	Rekenen aan spectroscopie, kinetiek, elektrochemie, complexen, buffers en activatieparameters.	Letter A-D. De sleutel zit alleen in de CSV.
Physics	6	Relativiteit, quantumpuut, Lagrangiaan, statistische mechanica, elektromagnetisme, zwakke zwaartekracht.	Zelfde letterscore.
Vision	3	Een beeld lezen: relatie, telling of een doolhof.	Alleen met een vision-adapter. Text-only wordt unsupported, geen 0%.
Video	3	Alleen een FFmpeg-filtergraph teruggeven, geen uitleg.	Lokaal renderen. Duur, formaat en bestandsgrootte tellen. Geen jury.
IQ	3	Een regel afleiden: recursie, syllogisme of een rooster.	Letterscore. Geen klinische IQ-test.
EQ	3	Een reactie kiezen die het bewijs volgt en geen motief verzint.	Letterscore. Geen klinische EQ-test.
FQ	2	Wielcommando's als JSON: links, rechts, duur.	Een differential-drive-simulator rekent positie en koers na.
QQ	4	Toestand, teleportatie, metrologie, variationele chemie.	Letterscore.
Finance	24	Feiten uit de eigen bestanden, plus modellering: OLS, tijdreeksen, risico, duration, leakage.	Letterscore. Historische modellen blijven leeg tot ze deze lane draaien.

Chemistry en Physics delen een holdoutbestand en worden gescheiden op het veld discipline. De overige lanes hebben elk een eigen CSV. Een privébestand in data/eval_cache/specialist_packs wint van de gevolgde starter, zodat een latere reeks kan roteren zonder de oude vragen te overschrijven.

Chemistry

De vragen zijn originele rekenopgaven op het niveau van een moeilijke graduate-set. De GPQA-publicatie is alleen de moeilijkheidsreferentie, niet de bron van de items. Een goed antwoord past een fysisch-chemische relatie toe en houdt eenheden en een verdunningsfactor bij. Typische onderwerpen zijn absorptie en concentratie, enzymkinetiek met een competitieve remmer, de Nernst-vergelijking, ligandveld, een buffer na toevoeging van sterk zuur, en Eyring-parameters.

Voorbeeld, niet gescoord. Een oplossing van 4,00 mL wordt aangelengd tot 20,00 mL. De verdunde oplossing heeft $A = 0,240$ in een cuvet van 1,000 cm. De molaire absorptiviteit is $1,20 \times 10^4 \text{ L mol}^{-1} \text{ cm}^{-1}$. Wat was de oorspronkelijke concentratie?

- A. $4,00 \times 10^{-6} \text{ M}$
- B. $1,00 \times 10^{-5} \text{ M}$
- C. $2,00 \times 10^{-5} \text{ M}$
- D. $1,00 \times 10^{-4} \text{ M}$ (antwoord)

Beer-Lambert geeft $c(\text{verdund}) = A / (\text{epsilon maal de weglengte}) = 2,00 \times 10^{-5} \text{ M}$. De verdunning is een factor 5, dus de oorspronkelijke concentratie is $1,00 \times 10^{-4} \text{ M}$. Dit getallenpaar staat niet in de chemistry-pack.

Physics

Ook dit zijn originele opgaven. Het model moet een formule kiezen en de orde van het effect goed hebben: snelheidsoptelling, een energiesprong in een oneindige put, een behouden grootheid uit een Lagrangiaan, een bezetting in een tweestandenstelsel, de intensiteit van een vlakke golf, en een klok in een zwak zwaartekrachtveld.

Voorbeeld, niet gescoord. Een schip beweegt met $0,60c$ ten opzichte van de aarde en vuurt een sonde vooruit af met $0,60c$ ten opzichte van het schip. Hoe snel beweegt de sonde ten opzichte van de aarde?

- A. $1,20c$
- B. $0,88c$ (antwoord)
- C. $0,60c$
- D. $0,36c$

De relativistische optelling $(0,6+0,6)/(1+0,6 \times 0,6) = 1,2/1,36$ is ongeveer $0,88c$. De suite gebruikt een ander snelheidspaar.

Vision

Het model krijgt een lokaal beeldpad en een korte vraag. De taken in de pack gaan over een ruimtelijke relatie, een telling van een kleur, en een route door donkere gangen. Zonder beeldadapter wordt de lane niet als mislukking genoteerd.

Voorbeeld, niet gescoord. Op een verder lege tekening staan vier cirkels: twee blauwe, een rode en een gele. Welk aandeel van de cirkels is blauw? Het beeld hoort bij de vraag; de tekst alleen is niet de test.

- A. $1/4$
- B. $1/2$ (antwoord)
- C. $3/4$
- D. 1

Twee van de vier cirkels zijn blauw. De pack telt andere vormen en een andere kleur.

Video

Het model mag alleen een filter_complex-expressie teruggeven. De harness roept ffmpeg aan met een vaste argv, rendert een MP4 en controleert afspeelduur en bestandsgrootte. Een uitleg, een shell-commando of een pad met een vreemd teken faalt. Er is een harde wandklok van vijf minuten.

Voorbeeld, niet gescoord. Geef alleen een filter_complex voor een MP4 van 4 seconden, 640x360, zwarte achtergrond, met een wit vierkant van 40x40 pixels in het midden. Geen shell, geen uitleg.

- A. color=c=black:s=640x360:d=4,drawbox=x=300:y=160:w=40:h=40:color=white:t=fill (antwoord)
- B. ffmpeg -i input.mp4 -vf scale=640:360
- C. movie=secret.mp4,overlay
- D. een alinea die het beeld beschrijft

Alleen de filtergraph is bruikbaar. De pack vraagt andere duren, resoluties en vormen. Dit voorbeeld wordt niet gerenderd.

IQ

De lane heet IQ omdat de taak abstracte regels zijn: een recursie uitrekenen, een syllogisme met verzonnen soorten, of een ontbrekend roostergetal. Het is geen psychometrische test en zegt niets over een persoon.

Voorbeeld, niet gescoord. Een rij is gegeven door $b_1 = 1$ en $b(n+1) = 3b(n) + 1$. Wat is b_3 ?

- A. 4
- B. 7
- C. 10
- D. 13 (antwoord)

$b_2 = 4$ en $b_3 = 13$. De pack gebruikt een andere startwaarde en een andere stap.

EQ

De juiste keuze is de reactie die het geobserveerde gedrag benoemt, geen motief verzint, en om een controleerbaar feit vraagt. Zelfverzekerd gokken, de ander de schuld geven of een belofte doen die het model niet kan waarmaken, zijn de afleiders.

Voorbeeld, niet gescoord. Een analist levert een rapport een dag later in en schrijft alleen: de bronbestand-datum klopte niet. Wat is de meest gekalibreerde volgende zin?

- A. Je bent te laat omdat je slordig bent.
- B. De datum in het bronbestand klopte niet volgens jouw bericht. Welke kolom en welke verwachte datum wijken af? (antwoord)
- C. Ik herstel het rapport vanavond, ongeacht de oorzaak.
- D. Negeer de vertraging. Het rapport is nu binnen.

B herhaalt het bewijs en vraagt een controleerbaar detail. De pack gebruikt andere situaties.

FQ

FQ is een robotlane. Het model levert JSON met hoeksnelheden van het linker- en rechterwiel en een duur. De scorer integreert een differential-drive: de lineaire snelheid is het gemiddelde van de wielsnelheden, de hoeksnelheid volgt uit het verschil gedeeld door de spoorbreedte. Het eindpunt en de koers moeten binnen een tolerantie van de opdracht liggen.

Voorbeeld, niet gescoord. Een robot staat op (0, 0) met koers 0 radialen. Wielstraal 0,04 m, spoorbreedte 0,20 m.

Welk commando rijdt ongeveer 0,25 m recht vooruit zonder te draaien?

- A. links 2 rad/s, rechts 2 rad/s, duur 3,1 s (antwoord)
- B. links 2 rad/s, rechts -2 rad/s, duur 3,1 s
- C. links 0, rechts 2 rad/s, duur 1 s
- D. links 5 rad/s, rechts 1 rad/s, duur 3,1 s

Gelijke wielsnelheden geven een rechte lijn. $v = 0,04 \times 2 = 0,08$ m/s, dus 0,25 m duurt ongeveer 3,1 s. Tegengestelde snelheden draaien op de plaats. De pack gebruikt andere maten.

QQ

De quantumlane blijft bij toestanden, meting, de hulpbron voor teleportatie, de schaling van fase-schatting, en de grootheid die een variationele eigensolver minimaliseert. Het zijn geen programmeeropdrachten voor een quantumcomputer.

Voorbeeld, niet gescoord. Een qubit staat in de gelijke superpositie van 0 en 1, geschreven (ket 0 plus ket 1) gedeeld door wortel 2. Die toestand wordt gemeten in de basis van diezelfde superpositie en de orthogonale superpositie (ket 0 min ket 1) gedeeld door wortel 2. Welke uitspraak klopt?

- A. De uitkomst is altijd de plus-superpositie. (antwoord)
- B. De uitkomst is altijd de min-superpositie.
- C. Beide uitkomsten hebben kans 1/2.
- D. De meting is ongedefinieerd omdat de toestand niet in de rekenbasis staat.

De toestand is precies de plus-superpositie, dus die uitkomst heeft kans 1. De pack meet een verstrengelde toestand in de rekenbasis, niet dit enkele qubitgeval.

Finance

Deze lane is op 24 september 2026 toegevoegd. Zij heeft twee soorten vragen, allebei met vier letters.

De eerste soort is een bestandfeit. Het antwoord staat in een kolom van EDS_latest.csv, crypto_metadata.parquet of crypto_gics_extended.parquet. Gevraagd worden de vastgelegde naam, het ISIN, de GICS-sectorcode en de officiële sectornaam daarbij, het domicilieland, de valutacode zoals het bestand die schrijft, de genesisdatum, een classificatielabel, en een founder-zin uit een opgeslagen beschrijving. Afleiders zijn andere waarden uit dezelfde bestanden of nabije codes. Marktkapitalisatie over landen heen is alleen vergelijkbaar na omrekening naar euro; de kolom daarvoor heet marketcap_eur.

De tweede soort is methode, zonder een rij uit het bestand. Zij dekt het werk van een CFA, een certified risk manager, een financial engineer en een machine-learning engineer op financiële tijdreeksen: de normale vergelijking van kleinste kwadraten, integratie-orde van een random walk, een correlatiematrix die positief semidefiniet moet zijn, expected shortfall tegenover VaR, renteduur, en lookahead wanneer het doel een rendement over de komende twintig dagen is.

Voorbeeld, niet gescoord. Een oefenbestand, niet de suite, heeft voor ticker EX01 de velden FMP_name = Noordkaap Energie, CountryDomicile_ISO2 = NO en Currency = NOK. Welke uitspraak is het bestandfeit?

- A. EX01 noteert in euro.
- B. De valutacode van EX01 is NOK en het domicilie is NO. (antwoord)
- C. EX01 is een Amerikaans aandeel omdat energiebedrijven dat meestal zijn.
- D. Het ISIN van EX01 begint met US.

Alleen B leest de gegeven velden. De gescoorde pack gebruikt echte tickers en de daar opgeslagen codes, niet EX01.

Voorbeeld, niet gescoord. Welke grootte is lookahead-lekkage als het doel een twintigdaags vooruitrendement is en de kenmerkendatum dag t is?

- A. het rendement van dag $t+1$ tot en met $t+20$ (antwoord)
- B. de slotkoers van dag t
- C. de gerealiseerde volatiliteit over de zestig dagen die op dag t eindigen
- D. een fundamenteel cijfer waarvan de publicatiedatum op of voor dag t ligt

A stopt het doel zelf in de features. B, C en D kijken niet na t . De pack formuleert de leakage-vraag met andere afleiders.

Wat de suite bewust niet doet

Zij vraagt niet om een portefeuille, een prijsvoorspelling of een handelsadvies. Een financiële specialist die een koers voorspelt zonder een vastgelegde uitkomst zou niet scoorbaar zijn. De feitenlanes hebben een sleutel in het bestand. De methodevragen hebben een verdedigbare letter. Voorspellingskwaliteit voor Numerai blijft in de aparte trainings- en submissionlijn, niet in deze CSV.

Zij gebruikt geen synthetische koersen. De bedrijf- en cryptofeiten zijn rijen die al in de databestanden stonden op het moment dat de pack is geschreven. Een voorbeeld in dit document dat ticker EX01 noemt, is didactisch en staat niet in de CSV.

Een model dat de letter weglaat, faalt ook als het betoog inhoudelijk klopt. Een model dat de letter raadt zonder het veld te gebruiken, faalt op de bestandfeiten zodra de afleider een bekende maar verkeerde code is.

Bronnen van de packs

Chemistry en Physics: config/benchmark_specialist_holdout_v1.csv. IQ, EQ, FQ, QQ, Vision, Video en Finance: config/specialist_benchmarks/. De runner staat in scripts/benchmarks/specialist_suite.py. Het dashboard labelt Finance als Finance, feiten en modellering. Publicatiedatum van die lane is 2026-09-24. De oudere lanes zijn gedateerd 2026-09-22.