

LLM-testsuite standaard & proces

Governance, meetprotocol, operationele instructie en
actuele benchmarkresultaten

DOCUMENTEIGENAAR
VirtualV AI Assurance

VERSIE
1.0

PEILDATUM
22 september 2026

CLASSIFICATIE
Intern gebruik

STATUS
Operationele standaard van de huidige
implementatie

BIJLAGEN
A · Instructiehandleiding B · Resultaten

Documentoverzicht

Dit gecontroleerde document combineert de norm, de werkinstructie en een gedateerde bewijsbijlage.

01 Doel en reikwijdte

02 Kernprincipes

03 Begrippen en statussen

04 Hardware en runtimes

05 Algemene kwaliteitssuite

06 Throughput

07 Specialisten en toegang

08 Bewijscontract

09 Operationeel proces

10 Wijzigingsbeleid

A Instructiehandleiding

B Actuele resultaten

Bronhiërarchie. De resultaat-JSON en ruwe logs zijn primair bewijs. Deze PDF is de bestuurlijk leesbare momentopname. Bij verschil prevaleert het herleidbare bronbewijs.

1. Doel en reikwijdte

Deze standaard beschrijft hoe VirtualV lokale large-language-models selecteert, uitvoert, meet, vergelijkt en archiveert. Het document geldt voor de publieke algemene suite, de afgeschermdede specialistensuite, hardwareprofielen, individuele modellen, mixtures en hervatbare cascades. Het is zowel een governancekader als een reproduceerbaar werkproces.

De standaard voorkomt drie veelvoorkomende fouten: scores vergelijken die onder een ander protocol zijn verkregen, throughput los van runtime en hardware presenteren, en mislukte of onuitvoerbare proeven als gemeten resultaat voorstellen. Alleen bewijs dat volgens dit document is vastgelegd, mag als VirtualV-benchmark worden gepubliceerd.

2. Kernprincipes

1. **Bewijs vóór conclusie.** Iedere score verwijst naar protocol, runtime, modelbron, hardwareprofiel en ruwe uitvoer.
2. **Kwaliteit en snelheid blijven gescheiden.** Tok/s is contextinformatie en geen vervanging voor taakaccuratesse.
3. **Vergelijk alleen gelijkwaardige runs.** Protocolversie, promptbeleid, context, engine en hardwaretopologie moeten zichtbaar zijn.
4. **Geen verzonnen uitkomsten.** OOM, ontbrekende kernel, timeout en onondersteunde modaliteit krijgen een expliciete status zonder fictieve score.
5. **Duurzame uitvoering.** Lange cascades draaien onder systemd, schrijven atomair en kunnen na een storing hervatten zonder bewezen resultaten te verliezen.
6. **Minimale toegang.** Evaluaties krijgen alleen de hulpmiddelen en gegevens die het gekozen profiel toestaat; echte home-, secret- en productiegegevens blijven buiten bereik.
7. **Behoud vóór opruimen.** Gewichten mogen pas worden verwijderd nadat een volledige, gevalideerde rij, herkomst, hash en herinstallatiepad duurzaam zijn opgeslagen.

3. Begrippen en statussen

Begrip	Betekenis
Model/checkpoint	De logisch benoemde gewichten met een vastgezette bron en revisie.
Quant	De concrete numerieke representatie, bijvoorbeeld GGUF IQ4_XS of NVFP4.
Engine	De uitvoerende runtime, bijvoorbeeld llama.cpp, qwen4exp of 1Cat-vLLM.
Hardwareprofiel	Fysieke GPU's, zichtbare devicevolgorde, topologie en split/parallelisatie.
Resultaatrij	Eén model- of mixture-uitvoering onder één aantoonbaar protocol.
Huidig-volledig	Geen fout, huidige protocolversie en alle vier composietcomponenten aanwezig.
Partieel	Geldige deelmetingen, maar niet voldoende voor de algemene ranglijst.
Niet ondersteund	Aantoonbaar onuitvoerbaar; geen snelheid of kwaliteit verzinnen.
Mislukt	De uitvoering stopte door een fout; logpad en foutreden blijven bewaard.

Begrip	Betekenis
Geblokkeerd	Een bekende externe of technische voorwaarde verhindert uitvoering.

Een status is zelf een resultaat. Alleen `huidig-volledig` mag in de algemene composietranglijst worden opgenomen.

4. Hardware- en runtimeprofielen

De fysieke GPU-indexering is vast en wordt niet afgeleid uit de volgorde die een runtime toevallig toont.

Fysieke index	GPU	Geheugen	Primaire rol
0	NVIDIA RTX A4000	16 GB-klasse	gemengd/all-four-profiel
1	Tesla V100-SXM2	32 GB	V100-paar, NVLink
2	Tesla V100-SXM2	32 GB	V100-paar, NVLink
3	NVIDIA RTX 4000 Ada	20 GB-klasse	gemengd/all-four-profiel

Voor iedere run geldt `CUDA_DEVICE_ORDER=PCI_BUS_ID`. De resultaatrij bevat ten minste `cuda_visible_devices`, fysieke GPU-identiteiten, uitgesloten GPU's, topologie, engine en decode-telemetrie.

De uitvoeringspaden worden strikt onderscheiden:

- **llama.cpp/GGUF:** lokale GGUF-gewichten; langdurige V100-runs gebruiken layer split. Tensor split is niet de standaard voor onbeheerde V100-runs door eerder waargenomen driver-handlefouten.
- **qwen4exp/llama.cpp:** experimentele Qwen-runtime voor Qwen3.8 Flash-Next GGUF en eventueel een afzonderlijk MTP-resultaat met passende draft-sidecars.
- **1Cat-vLLM:** zelfstandig vLLM-pad voor ondersteunde safetensors- en quantisatieruntimes. Een 1Cat-resultaat mag niet als llama.cpp-resultaat worden gepresenteerd of omgekeerd.
- **Mixture:** orkestratie over meerdere reeds gemeten modellen. De kwaliteitswinst is niet rechtstreeks gelijk aan de kosten of latency van één checkpoint en staat daarom in een aparte tabel.

De mislukte Qwen3.8 Flash-Next W4A16-proef betrof specifiek de gebruikte compressed-tensors/Merlin-route. Dit is geen algemene uitspraak dat alle W4A16- of 1Cat-vLLM-routes op SM70 onmogelijk zijn. Nieuwe 1Cat-branches of releases worden eerst op commit vastgezet, in een geïsoleerde omgeving gepreflight en pas na een volledige huidige-protocolrun bevorderd.

5. Algemene kwaliteitssuite

De geldende protocol-ID is `v4-mm1u-fewshot-20260918`. De openbare batterij is:

Onderdeel	Omvang	Meetwaarde
GSM8K	50 opgaven	hoogste geldige waarde van strict-match en flexible-extract
BBH	6 subtaken × 8 voorbeelden = 48	gemiddelde accuratesse

Onderdeel	Omvang	Meetwaarde
MMLU	8 vakgebieden × 20 vragen = 160	gemiddelde 5-shot accuratesse
TruthfulQA generation	30 prompts	contextdiagnostiek, niet in composiet
HumanEval	40 programmeertaken	pass@1 in geïsoleerde subprocessen

BBH omvat boolean expressions, causal judgement, date understanding, logical deduction met vijf objecten, navigation en temporal sequences. MMLU omvat abstract algebra, anatomy, astronomy, college computer science, high-school psychology, formal logic, professional law en marketing.

Generatie is deterministisch met `temperature=0` en de modelgebonden chat-template. Voor llama.cpp staat reasoning uit wanneer reasoning-content anders een leeg antwoordveld veroorzaakt. Stoptekens worden taakgericht gekozen; MMLU gebruikt `</s>`, `Q:` en `<|im_end|>`, terwijl BBH `</s>` en `Q` gebruikt. Een generieke newline-stop is verboden omdat die geldige antwoorden kan afkappen. De rescoring normaliseert alleen expliciete, losstaande keuzen.

De algemene composietscore is het ongewogen gemiddelde:

```
composiet = (GSM8K + BBH + MMLU + HumanEval) / 4
```

TruthfulQA en throughput worden getoond als context maar wijzigen deze score niet. Een model komt alleen in de ranglijst als alle vier componenten onder de huidige protocol-ID aanwezig zijn.

6. Throughputmeting

Throughput wordt gemeten met één deterministische completion van maximaal 256 outputtokens en `ignore_eos=True`, met GPU-telemetrie tijdens decode. De eenheid is completion tokens per seconde. De waarde is alleen betekenisvol naast engine, quant, context, parallelisatie en fysieke hardware.

MTP-resultaten krijgen een aparte rij en vervangen nooit de normale decode-meting. Target-only, MTP, prompt-prefill en pure decode mogen niet onder één label worden samengevoegd.

7. Specialistensuite en toegangsprofielen

De specialistensuite gebruikt protocol `v2-private-specialist-packs-vision-video-iq-eq-fq-qq-20260922`. De lanes zijn chemie, fysica, vision, video, IQ, EQ, FQ en QQ. Resultaten komen in `reports/specialist_suite_20260922.json` en tellen niet mee in de algemene composiet.

De openbare repository bevat startpakketten; geroteerde privésets staan onder de genegeerde map `data/eval_cache/specialist_packs`. Hashes van gebruikte packs worden in het resultaat opgeslagen en antwoordsleutels worden nooit aan het model aangeboden. FQ gebruikt een deterministische differentiële-drive-simulatie. Video verwacht een door het model opgesteld FFmpeg-filtergraph dat via vaste, veilige argumenten en een wandtijdlimiet van vijf minuten draait.

Profiel	Toegang
sandbox	alleen prompt en modelantwoord; geen externe hulpmiddelen
disk	synthetisch, alleen-lezen evaluatiearchief
internet_disk	hetzelfde archief plus gelogde, allow-listed webtool

Raw endpoints ondersteunen alleen sandbox. Geen profiel krijgt toegang tot de echte home-directory, gitcredentials, chatgeschiedenis, secrets of productiedata. Een tekstmodel krijgt voor vision/video de status `unsupported`, niet een nulscore die modelkwaliteit suggereert.

8. Bewijs- en herkomstcontract

Een publiceerbare rij bevat, waar van toepassing:

- model-ID, quantisatie, engine en engineversie;
- bronrepository, vastgezette revisie, publicatiedatum, gewichtsgrootte en SHA-256;
- protocol-ID, taakconfiguratie en scorer;
- fysieke GPU's, zichtbare devicevolgorde, topologie, context en splitbeleid;
- start/eindtijd, runtime, tok/s en GPU-decodetelemetrie;
- taakscores, composiet, status en fout- of logverwijzing.

Het primaire openbare resultaatbestand is `reports/well_known_suite_20260917.json`. Schrijfacties gaan via een tijdelijk bestand en atomaire vervanging. Nieuwe modelrijen mogen bestaande rijen niet stilzwijgend overschrijven. Ruwe logs staan per model onder `reports/lm_eval_runs/`; het dashboard wordt afgeleid naar `reports/dual_v100_nvlink_benchmark.html`.

9. Operationeel proces

1. **Intake.** Leg zakelijke vraag, modelbron, licentie, revisie, quant en verwachte geheugenbehoefte vast.
2. **Preflight.** Controleer bestandsgrootte/hash, architectuur, compute capability, kernels, vrije schijfruimte en incompatibele actieve services.
3. **Classificeer.** Kies engine, hardwareprofiel, context en suite. Nieuwe branches zijn kandidaat, geen productiestandaard.
4. **Reserveer.** Verkrijg de exclusieve GPU-lock, stop alleen bekende conflicterende diensten en verifieer dat geen compute-context resteert.
5. **Start.** Gebruik een expliciete commandoregel of een beheerde systemd-unit; schrijf state en gebeurtenis vóór elke lange fase.
6. **Evalueer.** Voer kwaliteit, throughput en relevante specialistlanes uit zonder protocolparameters tijdens de run te wijzigen.
7. **Persisteer.** Schrijf iedere duurzame overgang en resultaatrij atomair, inclusief foutstatus.
8. **Valideer.** Controleer volledigheid, protocol-ID, herkomst, GPU-mapping, scoreberekening en ruwe logs.
9. **Publiceer.** Herbouw het HTML-dashboard en deze gedateerde rapportage.
10. **Behoud of ruim op.** Verwijder uitsluitend een aantoonbaar lagere, volledige kandidaat nadat bewijs en reproduceerpad zijn veiliggesteld.
11. **Herstel.** Start eerder gestopte bekende diensten opnieuw, laat geen verweesde server achter en geef lock en poorten vrij.

De automatische lokale sweep draait iedere vijftien minuten met `/tmp/llm_bench_sweep.lock` en kiest maximaal één reeds lokaal aanwezig model zonder huidige resultaatrij. Er worden geen gewichten gedownload. De HTML-renderer draait afzonderlijk op minuut 17, 32, 47 en 57 met `/tmp/llm_bench_html.lock`.

10. Wijzigings- en acceptatiebeleid

Een wijziging in prompts, samples, few-shotvoorbeelden, stoptekens, normalisatie, scorer of aggregatie vereist een nieuwe protocol-ID. Oude rijen blijven historisch zichtbaar maar zijn niet automatisch rangschikbaar naast de nieuwe standaard. Een engine- of kernelwijziging zonder protocolwijziging vereist minimaal een nieuwe runtime-identificatie en een regressieproef.

Een kandidaat wordt geaccepteerd wanneer de run reproduceerbaar is, de bewijsvelden compleet zijn, de ruwe logs aansluiten, het resultaat door een tweede persoon of geautomatiseerde validatie is gecontroleerd en er geen onverklaarde score- of snelheidsafwijking bestaat.

11. Rollen en verantwoordelijkheden

Rol	Verantwoordelijkheid
Suite-eigenaar	protocol, acceptatiecriteria en wijzigingsbesluit
Operator	veilige uitvoering, monitoring, state en herstel
Reviewer	herkomst, logs, berekening en vergelijkbaarheid controleren
Rapportage-eigenaar	dashboard/PDF publiceren zonder brondata te wijzigen

Dezelfde persoon mag meerdere rollen uitvoeren, maar protocolwijzigingen en definitieve verwijdering van modelgewichten moeten aantoonbaar worden gereviewd.

Bijlage A — Instructiehandleiding voor operators

A.1 Voorbereiding

Werk vanuit de repository:

```
cd /media/knight2/EDS2/projects/numera-si-signals
```

Controleer vóór iedere handmatige actie de actieve services, GPU-processen, vrije ruimte en repositorywijzigingen:

```
systemctl --user status qwen38-flash-next-gguf-cascade.service --no-pager
nvidia-smi --query-compute-apps=gpu_uuid,pid,process_name,used_memory --format=csv,noheader
nvidia-smi --query-gpu=index,name,memory.used,memory.free,utilization.gpu --format=csv,noheader
df -h /media/knight2/EDS2
git status --short
```

Een actieve benchmark wordt niet onderbroken om documentatie te genereren. Start geen tweede run op dezelfde GPU's en omzeil de exclusieve lock niet.

A.2 Lokale algemene suite starten

Gebruik de één-model-scheduler voor reeds lokale kandidaten:

```
flock -n /tmp/llm_bench_sweep.lock \
python3 scripts/benchmarks/run_next_benchmark.py
```

Gebruik voor een expliciet model de runner met de lokaal vastgelegde configuratie:

```
python3 scripts/benchmarks/well_known_suite.py MODEL_ID \
--out reports/well_known_suite_20260917.json
```

Controleer eerst `--help`; voeg geen niet-bestaande optie toe en verander de protocolparameters niet ad hoc.

A.3 Externe of reeds draaiende endpoint meten

Bij een extern endpoint zijn fysieke GPU's, topologie en engine verplicht:

```
python3 scripts/benchmarks/well_known_suite.py MODEL_ID \
--external-url http://127.0.0.1:PORT \
--external-model SERVED_MODEL \
--physical-gpus 1,2 \
--topology '2x Tesla V100-SXM2-32GB + NVLink' \
--engine 'ENGINE_NAME' \
--out reports/well_known_suite_20260917.json
```

Gebruik alleen localhost of een expliciet goedgekeurde endpoint. Verifieer `/health` en modelalias vóór de suite start.

A.4 Qwen3.8 Flash-Next-cascade bedienen

De actieve cascade is hervatbaar en chat-onafhankelijk:

```
systemctl --user status qwen38-flash-next-gguf-cascade.service --no-pager
journalctl --user -u qwen38-flash-next-gguf-cascade.service -f
tail -f reports/benchmark_logs/qwen38_flash_next_gguf_cascade.service.log
```

Veilig stoppen en later hervatten:

```
systemctl --user stop qwen38-flash-next-gguf-cascade.service
systemctl --user start qwen38-flash-next-gguf-cascade.service
```

De duurzame state staat in `reports/qwen38_flash_next_gguf_cascade_20260922.json`. Bewerk dit bestand niet handmatig terwijl de service draait. De geplande volgorde is AP-IQ4_XS op het V100-paar en alle vier GPU's, daarna AP-Q4_K_M op beide profielen, dan selectie en pas daarna een afzonderlijke MTP-proef voor de winnaar.

A.5 Specialistensuite uitvoeren

Gebruik alleen aanwezige, gehashte packs en het minimaal benodigde toegangsprofiel:

```
python3 scripts/benchmarks/specialist_suite.py --help
```

Controleer vóór publicatie dat de packhash, lane, toolprofiel en status zijn opgeslagen. Deel privé vragen en antwoordsleutels niet in logs, dashboards of de PDF.

A.6 Monitoring

Volg proces, fase, loggroei en GPU-telemetrie. Een lage GPU-utilisatie kan normaal zijn tijdens datasetvoorbereiding, scorerwerk of een CPU-gebonden taak; beoordeel daarom ook proces-CPU en recente loggroei.

```
ps -eo pid,etime,%cpu,%mem,cmd | rg 'well_known_suite|specialist_suite|llama-server|vllm'
tail -n 80 reports/benchmark_logs/qwen38_flash_next_gguf_cascade.service.log
nvidia-smi dmon -s pucvmet
```

Fan Manager mag core-, hotspot- en geheugentemperaturen tonen voor zover de driver/sensor die levert. Een ontbrekende geheugentemperatuur wordt als niet beschikbaar gemarkeerd en nooit afgeleid uit de coretemperatuur.

A.7 Valideren en publiceren

Voer syntaxiscontrole uit op gewijzigde runners, controleer de JSON en bouw het dashboard opnieuw:

```
python3 -m py_compile scripts/benchmarks/*.py
python3 -m json.tool reports/well_known_suite_20260917.json >/dev/null
python3 scripts/benchmarks/build_dual_v100_html.py
git diff --check
```

Controleer vervolgens dat alleen huidige-volledige rijen gerangschikt zijn, de compositie uit exact vier componenten bestaat, mixture-resultaten apart staan en fouten zichtbaar blijven.

A.8 Incidentprocedure

1. Noteer tijd, service, model, engine, GPU's en laatste logregel.
2. Stop alleen de betrokken beheerde service; gebruik geen brede kill-opdracht.
3. Bewaar state, resultaat-JSON en logs vóór herstelwerk.
4. Controleer lock, poort, compute-context, vrije VRAM/schijf en bestandshash.
5. Herstel de oorzaak in code of configuratie en voer minimaal compile/dry-run uit.
6. Hervat via systemd en verifieer dat geen dubbele runner of download bestaat.
7. Registreer fout én herstel als duurzame gebeurtenis.

Nooit doen: een score handmatig invullen, een incomplete rij als voltooid markeren, een actieve productie- of benchmarkdienst willekeurig beëindigen, GPU-indexen aannemen zonder fysieke mapping, privé-evaldata archiveren of een modelmap verwijderen vóór de bewaartoets.

A.9 Afsluitchecklist

- Resultaat en foutstatus atomair opgeslagen.
- Protocol, engine, bronrevisie en hardwaretopologie aanwezig.
- Ruwe logs en state leesbaar.
- Geen verweesde servers of GPU-compute-contexten.
- Bekende lokale diensten hersteld.
- Dashboard opnieuw opgebouwd.
- Verwijdering, indien van toepassing, beperkt tot de gevalideerde verliezer.
- Codewijziging compileert en `git diff --check` is schoon.

Bijlage B — Actuele benchmarkresultaten

Momentopname: 22-09-2026 11:56:19 CEST · **Bron:** reports/well_known_suite_20260917.json · **SHA-256:** f69e93476e1002345835fdf5177f732486bf32ca0967395d4a93197570414de6
Omvang: 37 rijen; 24 individuele huidige-volledige resultaten; 9 huidige-volledige mixtures; 4 niet-rangschikbare rijen.
Cascade: service active; actieve fase bij opmaak: qwen38-flash-next-ap-iq4xs-allfour.

BESTE INDIVIDUELE COMPOSITET

qwen38-flash-next-ap-iq4xs-v100
91.9%

HOOGSTE GEMETEN DECODE

nemotron35-lightning-30b-a3b
127.78 tok/s

BESTE MIXTURE-COMPOSITET

mixture-optimized-6
95.2%

Leeswijzer. Compositet is het ongewogen gemiddelde van GSM8K, BBH, MMLU en HumanEval. Tok/s is contextgebonden en niet in de compositet opgenomen. Een mixture kan meerdere modelaanroepen en dus andere kosten/latency hebben; daarom staat die apart.

B.1 Individuele modellen en runtimes

#	Model / configuratie	Engine	Hardwareprofiel	GSM8K	BBH	MMLU	HumanEval	Compositet	tok/s
1	qwen38-flash-next-ap-iq4xs-v100	llama.cpp qwen4exp	2× Tesla V100-SXM2-32GB · NVLink · layer split	92.0%	93.8%	84.4%	97.5%	91.9%	42.40
2	qwen35-122b-a10b-iq3s	llama.cpp (historische rij)	2×V100 · layer	84.0%	91.7%	86.2%	97.5%	89.9%	49.19
3	kat-coder-v2.5-dev	llama.cpp-gguf	niet vastgelegd	94.0%	79.2%	85.0%	95.0%	88.3%	95.72
4	llama3-70b-instruct-q4	llama.cpp (historische rij)	2×V100 · layer	92.0%	81.2%	75.6%	95.0%	86.0%	15.50
5	granite-4.2-30b	llama.cpp-gguf	niet vastgelegd	92.0%	85.4%	70.6%	95.0%	85.8%	32.32
6	qwen38-27b-q4	llama.cpp-gguf	2×V100 · layer	94.0%	64.6%	84.4%	97.5%	85.1%	33.48
7	qwen36-35b-a3b-nvfp4	1cat-vllm-nvfp4-modelopt	niet vastgelegd	92.0%	68.8%	78.1%	97.5%	84.1%	114.81
8	nemotron35-lightning-30b-a3b	llama.cpp-gguf	niet vastgelegd	78.0%	79.2%	73.8%	97.5%	82.1%	127.78
9	devstral-small2-24b-q4	llama.cpp-gguf	2×V100 · layer	94.0%	56.2%	80.6%	95.0%	81.5%	34.86
10	mistral-small4-119b-q4-adaa4000	llama.cpp-gguf	physical GPU [0, 3] (A4000+RTX4000Ada), split=layer, n-cpu-moe=30	82.0%	64.6%	81.2%	97.5%	81.3%	11.58

#	Model / configuratie	Engine	Hardwareprofiel	GSM8K	BBH	MMLU	HumanEval	Composiet	tok/s
11	deepseek-v4-flash-reap150b-q2k-adaa4000	llama.cpp-gguf	physical GPU [0, 3] (A4000+RTX4000Ada), split=layer, n-cpu-moe=43, flash-attn=off	94.0%	87.5%	43.8%	90.0%	78.8%	5.85
12	qwen35-27b-q4	llama.cpp-gguf	2xV100 · layer	90.0%	41.7%	81.9%	92.5%	76.5%	32.78
13	qwen25-72b-q4	llama.cpp-gguf	2xV100 · layer	72.0%	52.1%	86.2%	95.0%	76.3%	14.86
14	command-r-plus-104b-0824-iq3m	llama.cpp (historische rij)	2xV100 · layer	74.0%	81.2%	77.5%	52.5%	71.3%	10.72
15	gemma4-26b-a4b-q4	llama.cpp-gguf	2xV100 · layer	82.0%	4.2%	75.6%	97.5%	64.8%	84.07
16	mixtral-8x22b-instruct-q3ks	llama.cpp (historische rij)	2xV100 · layer	82.0%	83.3%	71.9%	12.5%	62.4%	19.08
17	llama31-70b-instruct-q4	llama.cpp-gguf	2xV100 · layer	80.0%	83.3%	80.0%	0.0%	60.8%	15.49
18	glm53-flash-aj-iq2xxs	llama.cpp (historische rij)	4 GPU's · layer	82.0%	83.3%	70.6%	5.0%	60.2%	21.49
19	gpt-oss-120b-q4	llama.cpp (historische rij)	2xV100 · layer	54.0%	64.6%	63.1%	50.0%	57.9%	96.81
20	gpt-oss-20b-q4	llama.cpp (historische rij)	RTX A4000	50.0%	64.6%	50.6%	52.5%	54.4%	99.44
21	wizardlm2-8x22b-iq3s	llama.cpp (historische rij)	2xV100 · layer	68.0%	60.4%	66.2%	7.5%	50.5%	25.90
22	muse-glimmer-30b	llama.cpp-gguf	niet vastgelegd	42.0%	47.9%	68.1%	7.5%	41.4%	34.27
23	qwen38-1cat-vllm-target	1cat-vllm-nvfp4-target	niet vastgelegd	30.0%	39.6%	43.8%	22.5%	34.0%	—
24	deepseek-r1-qwen32b-q4	llama.cpp-gguf	2xV100 · layer	68.0%	0.0%	60.6%	2.5%	32.8%	29.44

Rangschikking binnen de actuele individuele huidige-volledige rijen. Een score zegt niets over licentie, totale gebruikskosten of geschiktheid voor een specifieke productiefLOW.

B.2 Mixtures en orkestratie

#	Model / configuratie	Engine	Hardwareprofiel	GSM8K	BBH	MMLU	HumanEval	Composiet	tok/s
1	mixture-optimized-6	mixture(6)	niet vastgelegd	98.0%	97.9%	87.5%	97.5%	95.2%	—
2	mixture-optimized-5	mixture(5)	niet vastgelegd	98.0%	95.8%	88.1%	97.5%	94.9%	—
3	mixture-optimized-4	mixture(4)	niet vastgelegd	94.0%	95.8%	88.1%	97.5%	93.9%	—
4	mixture-optimized-3	mixture(3)	niet vastgelegd	94.0%	91.7%	86.9%	97.5%	92.5%	—
5	mixture-of-models-4-quality	mixture(4)	niet vastgelegd	98.0%	89.6%	84.4%	97.5%	92.4%	—
6	mixture-of-models-4-gemma-routed	mixture(4)	niet vastgelegd	94.0%	87.5%	86.9%	97.5%	91.5%	—
7	mixture-of-models-4-gemma-direct	mixture(4)	niet vastgelegd	96.0%	87.5%	83.8%	97.5%	91.2%	—
8	mixture-of-models	mixture(3)	niet vastgelegd	96.0%	81.2%	86.2%	97.5%	90.2%	—
9	mixture-optimized-2	mixture(2)	niet vastgelegd	82.0%	91.7%	86.2%	97.5%	89.4%	—

Mixture-resultaten gebruiken dezelfde vier kwaliteitscomponenten, maar vormen geen één-op-één snelheidsvergelijking met één checkpoint. Ontbrekende tok/s wordt als — getoond.

B.3 Niet-rangschikbare, mislukte of partiële rijen

Model	Engine	Hardware	Toelichting
glm45-air-106b-q4	llama.cpp (historische rij)	niet vastgelegd	Past niet als gewone 50/50 V100-layer-split. Met zware CPU-offload werd 7,57 tok/s gemeten, onder de ingestelde snelheidsdrempel; daarom bestaat geen composietscore.
glm53-reap50-iq3m-v100	llama.cpp (historische rij)	niet vastgelegd	llama-server stopte tijdens initialisatie; de fout is bewaard en er is geen score afgeleid.
qwen38-flash-next-merlin-w4a16-v100	1Cat-vLLM 1.5.0	2x Tesla V100-SXM2-32GB + NVLink	De specifieke 1Cat-vLLM compressed-tensors/Merlin-route stopte vóór de suite. Dit bewijst niet dat iedere W4A16-route of 1Cat-branch op SM70 onmogelijk is.
qwen38-flash-next-merlin-w4a16-allfour	1Cat-vLLM 1.5.0	RTX A4000 + 2x V100 NVLink + RTX 4000 Ada	De specifieke 1Cat-vLLM compressed-tensors/Merlin-route stopte vóór de suite. Dit bewijst niet dat iedere W4A16-route of 1Cat-branch op SM70 onmogelijk is.

B.4 Zakelijke duiding

- Gebruik de composiet als brede kwaliteitsindicator, niet als zelfstandig productiebesluit.
- Bekijk voor capaciteit alleen runs met dezelfde engine, quant, context en hardwaretopologie.
- De 1Cat-vLLM-rijen en llama.cpp/GGUF-rijen zijn verschillende uitvoeringspaden.
- Een fout- of unsupported-rij blijft zichtbaar als auditbewijs en krijgt geen fictieve nul- of snelheidsscore.
- Een actieve run komt pas in de tabel na atomaire voltooiing en een nieuwe PDF-build.